关于 Lab 3 数据集 a9a 的使用说明

求解问题回顾

Lab 3 要求求解 Logistic Regression 问题的最优解，也即求解如下的最优化问题：

$$\min_{x\in\mathbb{R}^n} \ell(x) = \frac{1}{m}\sum_{i=1}^{m} \ln\left(1+\exp(-b_i a_i^\top x)\right) + \lambda \left\|x\right\|^2$$

其中，$a_i \in \mathbb{R}^n, b_i \in \{-1,1\}, i=1,2,\ldots,m$ 是给定的数据，$\lambda = \frac{1}{100m} > 0$ 是给定的正数。

可以看到上述问题中涉及到的参数有：

- m 个 n 维向量 $a_i, i=1,2,\ldots,m$
- m 个标量 $b_i, i=1,2,\ldots,m$

这些参数需要从提供的数据集中获取。

数据集说明

本次实验使用 a9a 数据集，群文件中的相关文件如下：

```
a9a.txt         \\ 文本文件格式的数据集
a9a.txt.mat     \\ .mat格式的数据集
data_a9a_load.m \\ .txt数据集转.mat数据集脚本（不用管）
```

本次实验中使用 `a9a.txt` 或 `a9a.txt.mat` 都可。

`a9a.txt.mat` 文件说明

这是一个 `MATLAB` 的 .mat 格式数据，可以使用 `MATLAB` 或者 `python` 的 `scipy.io.loadmat` 函数读取。以 `MATLAB` 读取为例，直接鼠标双击打开后，可以看到 `data` 为 1×2 的 cell，其中

- 第一个元素为 123×32561 的稀疏双精度矩阵。每一列表示一个向量 $a_i \in \mathbb{R}^{123}, i=1,2,\ldots,123$，也即 $n=123, m=32561$；
- 第二个元素为 32561×1 的双精度向量，每个元素都为 1 或 -1。

> 注意：cell 中的第一个元素是稀疏矩阵，默认情形下是按照 `(行索引,列索引),元素值` 格式存储的（类似于十字链表）

`a9a.txt` 文件说明

这是原始的文本格式的数据，存储的空间效率比 .mat 文件低。其中的数据格式如下：

- 每一行表示一对 (b_i, a_i)
- 每行的第一个数表示 b_i，后面的每个 $x:y$ 表示 a_y 的第 x 个分量值为 1（没错，a_i中只有$0,1$两种取值）

以第一行为例：

```
-1 3:1 11:1 14:1 19:1 39:1 42:1 55:1 64:1 67:1 73:1 75:1 76:1 80:1 83:1
```

表示$b_1=-1$, a_i 中只有第 $3,11,14,19,39,42,55,64,67,73,75,76,80,83$ 个分量为1，其他分量都为0。

> PS: 推荐使用 .mat 文件，会方便一些。